Travaux Pratiques.
Initiation à la simulation de variables aléatoires

Yves Achdou

29 septembre 2026

Dans tout le TP, on utilisera l'onglet `help` dans jupyter pour accéder aux informations concernant les commandes suggérées dans le texte ci-dessous.

1. Commencer par écrire les commandes :
```
import numpy as np
import scipy.linalg as linalg
import scipy.stats as stats
import matplotlib.pyplot as plt
```

2. **Variables discrètes**
   (a) Écrire une fonction permettant de tirer n prénoms, indépendamment, dans l'ensemble
   $$E = \{\text{Elise}, \text{Raphael}, \text{Mickael}, \text{Juliette}\}.$$
   avec les probabilités 1/6 pour Juliette et Raphaël et 1/3 pour Élise et Mickaël. On utilisera la commande `np.random.choice`. Tirer de cette façon 10000 prénoms
   (b) En utilisant `np.random.seed` avant l'appel de la fonction précédente (`np.random.seed` permet de générer la graine d'aléas), montrer qu'on peut reproduire le même tirage.
   (c) En utilisant la commande `np.unique`, créer un dictionnaire qui associe à chaque prénom le nombre de fois qu'il a été tiré. Pour créer le dictionnaire, on utilisera `dict` et `zip`

3. **Simulation de lois classiques avec numpy**
   (a) Tirer une liste de n nombres réels aléatoires, suivant la loi normale standard. On utilisera `np.random.standard_normal`
   (b) Tirer une liste de n nombres aleatoires, suivant la loi normale de moyenne 3, et d'écart-type 4. On le fera de deux manière, soit en partant du tirage de la question précédente, soit en utilisant `np.random.normal`
   (c) Afficher un histogramme correspondant au tirage précédent, entre -20 et 20, avec 200 cases, en renormalisant pour que l'aire de l'histogramme soit égale à 1. On utilisera `plt.hist`
   (d) Sur le même graphique, superposer le graphe de la densité de probabilité de la loi normale de moyenne 3, et d'écart-type 4. On utilisera `stats.norm`.
   (e) faire varier n, par exemple $n = 10^3, 10^4, 10^5, 10^6$.

4. **Vecteurs Gaussiens**
   (a) Tirer une liste de 10^5 vecteurs de $\mathbb{R}^2$, suivant les loi normales de moyennes $(0, 0)$ et de matrice de covariance $\begin{pmatrix} 6 & -3 \\ -3 & 3.5 \end{pmatrix}$ et $\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$ en utilisant `np.random.multivariate_normal`
   (b) Les représenter avec `plt.scatter`

5. **Méthode de Monte-Carlo**

La méthode de Monte-Carlo est basée sur la loi des grands nombres. Elle permet par exemple de calculer des valeurs approchées d'intégrales ou d'espérances, en utilisant des réalisations i.i.d. d'une loi que l'on sait simuler. Par exemple, si $(X_n)_{n\geq 1}$ est une suite de variables aléatoires i.i.d. de loi uniforme sur $[0,1]$ et si $f : [0,1] \mapsto \mathbb{R}$ est une fonction intégrable par rapport à la mesure de Lebesgue sur $[0,1]$, alors la loi des grands nombres entraîne la convergence presque-sûre suivante :

$$\begin{aligned} \frac{1}{n}\sum_i f(X_i) &\rightarrow \mathbb{E}(f(X_1)) \text{ p.s.} \\ &= \int_{[0,1]} f(x)dx. \end{aligned}$$

Si on sait majorer la variance de $f(X_1)$, on est de plus en mesure de fournir des intervalles de confiance pour contrôler l'erreur commise dans l'approximation. La convergence de cette méthode (convergence en $1/\sqrt{n}$) est lente par rapport à des méthodes déterministes. Cependant cette vitesse ne dépend pas de la régularité de l'intégrande f ni de la dimension, contrairement aux méthodes déterministes.

(a) Approcher par la méthode de Monte-Carlo l'aire du disque unité, en utilisant le fait qu'elle est égale à $\int_0^1 4\sqrt{1-x^2}dx$.

(b) Approcher par la méthode de Monte-Carlo le volume de la boule unité de $\mathbb{R}^3$, en utilisant le fait qu'il est égal à $\int_{[-1,1]^3} 1_{x^2+y^2+z^2\leq 1}dxdydz$

6. **Simulation de variables aléatoires par la méthode de la transformée inverse**

En théorie des probabilités, la *fonction de répartition*, ou *fonction de distribution cumulative*, d'une variable aléatoire réelle X est la fonction F_X qui, à tout réel x associe la probabilité d'obtenir une valeur inférieure ou égale à x :

$$F_X(x) = \mathbb{P}(X \leq x).$$

Pour une fonction de répartition F, notons F^{-1} la fonction définie pour $\omega \in]0,1[$ par $F^{-1}(\omega) = \inf\{x \in \mathbb{R} \mid F(x) \geq \omega\}$. Notons que si F est continue et strictement croissante, alors F^{-1} est tout simplement la réciproque de F. Pour cette raison, F^{-1} est parfois appelée *réciproque généralisée de* F. On l'appelle aussi *fonction quantile*.

Théorème *Si U désigne une variable aléatoire réelle uniforme sur $[0,1]$, alors $X = F^{-1}(U)$ a pour fonction de répartition F.*

(a) Quelle est la fonction de répartition de la loi de Bernoulli $\mathcal{B}(p)$? Quelle est sa réciproque généralisée ?

(b) À partir de variables uniformes, simuler en utilisant le théorème précédent un échantillon $(X_1, ..., X_n)$ de variables aléatoires de loi exponentielle de paramètre 2.

(c) Pour plusieurs valeurs de n, tracer un histogramme, et superposer le graphe de la densité.

7. **Simulation de variables aléatoires par la méthode de rejet (Rejection sampling)**

Soit λ_n la mesure de Lebesgue sur $\mathbb{R}^n$. Étant donné A une partie Borélienne de $\mathbb{R}^n$ telle que $\lambda_n(A) > 0$, la mesure uniforme sur A est la mesure de probabilité $\frac{1}{\lambda_n(A)}\lambda_n|_A$.

Proposition *Soient A et D des parties Boréliennes de $\mathbb{R}^n$ telles que $A \subset D$ et $\lambda_n(A) > 0$. Soit $(X_i)_{i\in\mathbb{N}}$ une suite i.i.d. de variables aléatoires dans $\mathbb{R}^n$ définies sur un espace de probabilité $(\Omega, \mathcal{T}, \mathbb{P})$, de loi uniforme sur D. Introduisons le temps $\tau := \inf\{i \in \mathbb{N}^* : X_i \in A\}$. La loi de X_τ est la loi uniforme sur A. De plus, $\mathbb{P}(\tau = k) = p(1-p)^{k-1}$ avec $p = \lambda_n(A)/\lambda_n(D)$, c'est-à-dire*

que τ suit la loi géométrique $G(p)$, donc $\mathbb{E}(\tau) = \lambda_n(D)/\lambda_n(A)$, et on peut montrer que τ et X_τ sont indépendantes.

En d'autres termes, en tirant des points aléatoirement dans D jusqu'à trouver un point dans A, il faut effectuer en moyenne $\lambda_n(D)/\lambda_n(A)$ tirages pour obtenir un point dans A, et le point obtenu est uniformément réparti dans A.

La méthode de rejet est utilisée pour engendrer indirectement une variable aléatoire X dans $[0,1]$, dont la loi μ a pour densité de probabilité f, quand on ne sait pas simuler directement μ.

Methode de rejet : supposons la densité f bornée par une constante $c > 1$. On considère deux suites i.i.d. de variables aléatoires dans $(Y_i)_{i\in\mathbb{N}}$ et $(U_i)_{i\in\mathbb{N}}$ dans $[0,1]$, indépendantes. Soit $\tau = \inf\{i \in \mathbb{N}, f(Y_i) \geq cU_i\}$. En utilisant la proposition ci-dessus ou le calcul ci-dessous, on peut déduire que X_τ a pour loi μ.

Considérons en effet (Y, U) un couple de variables aléatoires indépendantes dans $[0,1]$, de loi uniforme. On considère la variable aléatoire

$$X = \mathbb{E}(Y | f(Y) > cU).$$

On voit que

$$\begin{aligned}
\mathbb{P}(X \leq x) &= \frac{\mathbb{P}\left(Y \leq x \text{ et } f(Y) > cU\right)}{\mathbb{P}\left(f(Y) > cU\right)} \\
&= \frac{\int_0^x \int_0^{\frac{f(y)}{c}} dudy}{\int_0^1 \int_0^{\frac{f(y)}{c}} dudy} \\
&= \frac{\int_0^x \frac{f(y)}{c} dy}{\int_0^1 \frac{f(y)}{c} dy} \\
&= \int_0^x f(y)dy,
\end{aligned}$$

donc la loi de X est f.

Pour simuler une suite de variables aléatoires réelles $(X_q)_{q\geq 1}$ de loi f, il suffit donc, dans une suite de tirages de couples (Y_i, U_i) uniformes indépendants, de sélectionner les Y_i correspondant aux tirages (Y_i, U_i) vérifiant $f(Y_i) \geq cU_i$, et de rejeter les autres.

Un pseudo-code pour l'algorithme de la méthode de rejet est le suivant :

Algorithme
- Boucle : tant que $cU > f(Y)$:
  - Tirer Y selon la loi uniforme sur $[0,1]$;
  - Tirer U selon la loi uniforme sur $[0,1]$, indépendamment de Y.
- Accepter Y comme un tirage aléatoire de densité de probabilité f.

Pour simuler un échantillon $(X_1, ..., X_q)$ de variables aléatoires de loi f, utiliser q fois l'algorithme précédent.

(a) Écrire une fonction implémentant une méthode de rejet pour simuler n échantillons d'une loi de densité $f(x) = \frac{\pi}{2}\sin(\pi x)$ sur l'intervalle $[0,1]$.

(b) Simuler un échantillon de 1000 de variables aléatoires de loi f, et tracer l'histogramme. Lui superposer le graphe de f.

(c) On pourra programmer une version vectorisée de la fonction précédente en effectuant le rejet sur m candidats à la fois, en évitant ainsi le `while`

(d) On peut généraliser la méthode ci-dessus de la façon suivante.

Si Y et U sont des variables aléatoires indépendantes respectivement dans $\mathbb{R}$ et dans $[0,1]$, de lois respectives g et $1_{[0,1]}$. Soit f une densité de probabilité sur $\mathbb{R}$. On suppose qu'il existe une constante $c \geq 1$ telle que $\forall y \in \mathbb{R}, f(y) \leq cg(y)$.

On considère la variable aléatoire

$$X = \mathbb{E}(Y | f(Y) > cg(Y)U).$$

On voit que

$$\begin{aligned}
\mathbb{P}(X \leq x) &= \frac{\mathbb{P}\left(Y \leq x \text{ et } f(Y) > cg(Y)U\right)}{\mathbb{P}\left(f(Y) > cg(Y)U\right)} \\
&= \frac{\int_{\infty}^{x} \mathbb{1}_{g(y)>0} g(y) \int_{0}^{\frac{f(y)}{cg(y)}} du dy}{\int_{\mathbb{R}} \mathbb{1}_{g(y)>0} g(y) \int_{0}^{\frac{f(y)}{cg(y)}} du dy} \\
&= \frac{\int_{-\infty}^{x} \frac{f(y)}{c} dy}{\int_{\mathbb{R}} \frac{f(y)}{c} dy} \\
&= \int_{-\infty}^{x} f(y) dy,
\end{aligned}$$

donc la loi de X est f.

On suppose qu'on sait facilement simuler des variables aléatoires de loi de densité g. Soient $(Y_i)_{i\in\mathbb{N}}$ une suite i.i.d. de variables aléatoires dans $\mathbb{R}$ de densité g et $(U_i)_{i\in\mathbb{N}}$ une suite i.i.d. de variables aléatoires uniformes sur l'intervalle $[0, 1]$, indépendantes de $(Y_i)_{i\in\mathbb{N}}$. Soit $\tau := \inf\{i \geq 1, f(Y_i) > cg(Y_i)U_i\}$, alors Y_τ a pour densité f..

Le but est d'appliquer cette méthode pour simuler la loi gaussienne standard de densité $f(x) = \frac{1}{\sqrt{2\pi}} e^{\frac{x^2}{2}}$ à partir de simulation d'une loi de densité $g(x) = \frac{1}{2} e^{-|x|}$.

On peut montrer facilement la majoration : pour tout $x \in \mathbb{R}$,

$$f(x) \leq \frac{\sqrt{2e}}{\sqrt{\pi}} g(x).$$

i. Montrer que si ϵ suit une loi de Bernoulli de paramètre $1/2$ dans $\{-1, 1\}$ et si Z est une variable exponentielle de paramètre 1 indépendante de ϵ, alors $Y = \epsilon Z$ a pour densité la fonction g sur $\mathbb{R}$.

ii. Implémenter un algorithme qui simule une variable gaussienne par la méthode de rejet (puis vectoriser la fonction programmée si affinité).

iii. simuler 10^6 variables avec cet algorithme et vérifier que l'histogramme correspondant approche bien la densité gaussienne. On pourra utiliser `stats.norm.pdf` pour f.

8. **La méthode de Box-Müller**

Si U et V sont deux variables aléatoires de loi uniforme sur $[0, 1]$, on considère la variable aléatoire W dans $\mathbb{R}^2$ définie par $W = (\sqrt{-2\ln(U)}\cos(2\pi V), \sqrt{-2\ln(U)}\sin(2\pi V))$.

(a) Écrire une fonction qui simule n échantillons indépendants de W, et représenter ces échantillons.

(b) Tirer de la sorte 10^5 échantillons. Tracer un histogramme pour les deux coordonnées et superposer le graphe de la densité de la loi normale standard en utilisant `stats.norm`. Qu'observe-t-on ?

(c) Calculer la matrice de covariance empirique pour 10^4, 10^5, 10^6 échantillons.